

# Maiores Vazamentos de Dados do Mundo

Analise Exploratoria, Machine Learning e Insights de Seguranca

Periodo 2004-2022 | 417 incidentes | 14.3 bilhoes de registros expostos

**417**

INCIDENTES

**14.3 bi**

REGISTROS EXPOSTOS

**18**

REINCIDENTES

**2004-2022**

PERIODO

## Neste relatório

---

- 1 Sumário executivo
- 2 Quando os ataques acontecem (sazonalidade)
- 3 Como os dados vazam (métodos)
- 4 Quem é alvo recorrente (reincidência)
- 5 O que os modelos aprenderam (machine learning)
- 6 Insights e recomendações

**Sobre o conjunto de dados.** A base reúne os maiores vazamentos de dados publicamente documentados entre 2004-2022, totalizando 417 incidentes. Cada registro descreve a organização afetada, o setor, o método de ataque, o volume de dados expostos, a sensibilidade da informação e a data do incidente.

## 1 Sumario executivo

Entre 2004-2022, foram catalogados **417 grandes vazamentos de dados**, expondo o equivalente a **14.3 bilhoes de registros**. A analise revela uma tendencia clara: os incidentes nao so se tornaram mais frequentes ao longo da decada, como cresceram em **magnitude** -- megavazamentos de centenas de milhoes de registros, raros no inicio do periodo, tornaram-se recorrentes a partir de 2018.

O ataque por invasao direta (**Hacked**) domina o cenario, respondendo por **66%** de todos os incidentes e pelo maior volume de dados expostos (**9.27 bilhoes** de registros). Falhas humanas e de configuracao, porem, permanecem relevantes e frequentemente evitaveis -- um lembrete de que parte importante do risco nao vem de adversarios sofisticados, mas de controles basicos ausentes.



Figura 1 - Frequencia (barras) e volume exposto (linha) por ano. A divergencia entre as duas curvas evidencia o aumento da magnitude por incidente.

## 2 Quando os ataques acontecem

Ao decompor os incidentes por mes, observa-se concentracao em **Mai** (48 incidentes), seguido pelos meses de meio e fim de ano. Embora vazamentos ocorram o ano inteiro, esse padrao sugere janelas de maior exposicao -- uteis para planejar campanhas de conscientizacao e reforco de monitoramento.




Figura 2 - Distribuicao dos incidentes ao longo dos meses do ano.

**Leitura de negocio:** a sazonalidade nao substitui vigilancia continua, mas indica periodos em que as equipes de seguranca devem elevar o nivel de alerta e antecipar auditorias e simulacoes de incidente.

### 3 Como os dados vazam

Nem todo metodo e igualmente destrutivo. O **Hacked** lidera tanto em frequencia quanto em volume, mas categorias como **Poor Security** (ma configuracao) e **Lost / Stolen Device** mostram que parte expressiva das exposicoes decorre de falhas operacionais -- nao de ataques sofisticados.




Figura 3 - Total de registros expostos agregado por metodo de ataque.

**Insight:** uma fracao relevante dos vazamentos e evitavel com controles basicos -- criptografia de dispositivos, gestao de acessos e revisao de configuracoes de nuvem. Esses controles tem alto retorno por exigirem investimento comparativamente baixo.

## 4 Quem e alvo recorrente

De todas as organizacoes analisadas, **18** sofreram mais de um vazamento no periodo. A lider, **Facebook**, acumula **5 incidentes**. A reincidencia concentra-se em grandes plataformas digitais, refletindo tanto a superficie de ataque ampliada quanto o valor dos dados que custodiam.




Figura 4 - Organizacoes com mais de um vazamento documentado no periodo.

**Implicacao:** vazar mais de uma vez sugere causa-raiz nao resolvida. Essas organizacoes merecem um processo de pos-incidente estruturado e acompanhamento continuo, em vez de remediacao pontual.

## 5 O que os modelos aprenderam

### 5.1 Classificacao -- e possivel prever o metodo de ataque?

Treinamos um Random Forest para prever o metodo a partir de setor, ano e tamanho do vazamento. O modelo atingiu **52%** de acuracia, *abaixo* do baseline ingenuo de 66% (sempre prever 'Hacked'). Esse resultado e, em si, o achado: **setor, ano e volume nao determinam o metodo de ataque** -- a escolha do vetor depende de fatores nao capturados nesses atributos (postura de seguranca, motivacao do atacante, oportunidade). Honestidade analitica vale mais que uma metrica inflada.

### 5.2 Clustering -- perfis de incidente

| Cluster | Incid. | Ano med. | Reg. medianos | Sensib. | Setor top |
|---------|--------|----------|---------------|---------|-----------|
| 0       | 140    | 2010.8   | 1.000.000     | 1.8     | Web       |
| 1       | 164    | 2018.6   | 10.800.000    | 1.6     | Web       |
| 2       | 113    | 2015.8   | 1.700.000     | 4.0     | Health    |

O K-Means (k=3, silhueta 0.314) separou naturalmente os incidentes em perfis distintos: vazamentos antigos e pequenos; megavazamentos recentes de baixa sensibilidade; e incidentes de **alta sensibilidade** concentrados em saude -- os mais criticos para os titulares dos dados.




Figura 5 - Incidentes projetados em 2D (PCA) e coloridos pelo cluster atribuido.

### 5.3 Deteccao de anomalias -- fora da curva

Um Isolation Forest sinalizou **21 vazamentos atipicos** (~5%) -- casos que destoam do padrao por combinarem extremos de volume, sensibilidade ou epoca. Entre eles, megavazamentos como Shanghai Police e LinkedIn, e casos peculiares de alta sensibilidade com baixissimo volume. Sao exatamente os incidentes que merecem investigacao manual prioritaria.




Figura 6 - Em vermelho, os incidentes sinalizados como anomalos pelo modelo.

**Uso pratico:** modelos de anomalia funcionam como uma fila de triagem -- apontam onde a atencao humana, sempre escassa, rende mais. Comece pelos 5% mais atipicos.



## 6 Insights e recomendacoes

- 1. Tratar invasao como ameaca-base.** Com 66% dos incidentes sendo 'Hacked', controles anti-intrusao (MFA, patching, deteccao continua) devem ser o piso, nao o teto.
- 2. Atacar o evitavel primeiro.** Falhas de configuracao e dispositivos perdidos respondem por parcela significativa e barata de mitigar: criptografia obrigatoria e revisao de buckets de nuvem.
- 3. Vigilancia reforcada na alta temporada.** Concentre auditorias e simulacoes nos meses de pico (lidera Mai), sem relaxar no restante do ano.
- 4. Monitorar reincidentes de perto.** As 18 organizacoes reincidentes precisam de pos-incidente estruturado -- vazar duas vezes indica causa-raiz nao resolvida.
- 5. Priorizar dados sensiveis (saude).** O cluster de alta sensibilidade exige protecao reforcada: o dano por registro e muito maior, mesmo com volumes menores.
- 6. Usar anomalias como fila de triagem.** Modelos de deteccao apontam onde a investigacao humana rende mais -- comece pelos 5% mais atipicos.

**Metodologia.** Limpeza e padronizacao em Pandas; visualizacao em Plotly e Matplotlib; modelagem em scikit-learn (Random Forest para classificacao, K-Means para clustering, Isolation Forest para deteccao de anomalias). Fonte: 'World's Biggest Data Breaches & Hacks'.